
TECH CHALLENGE – POSTECH BB

Previsão de Inadimplência

Predição de bons e maus pagadores com aprendizado de máquina



Marcia Paula Soares Vieira
Marcos Yuiichi Gomes Okada
Milton Cardoso de Paula Junior
Natalia Diniz Figueiredo Ramiro
Zildomar Aranha de Carvalho Filho

Crédito é uma decisão de velocidade — e de risco

A instituição precisa responder rápido aos pedidos de cartões de crédito pelos clientes sem transformar agilidade em inadimplência.



Agilidade

Avaliar muitos pedidos com consistência e escala.



Risco

Evitar aprovações com maior probabilidade de mau pagamento.

A oportunidade é transformar histórico em recomendação objetiva.

PERGUNTA CENTRAL

Dado o perfil de um cliente, há indícios de risco de inadimplência?



Classificação

Distinguir bons e maus pagadores com base nas evidências disponíveis.



Probabilidade

Quantificar o risco para tornar a decisão mais mensurável e consistente.



Encaminhamento

Apoiar a aprovação, a revisão humana ou a recusa de um novo pedido.

Antes do modelo, entendemos o comportamento da base

A análise exploratória revela como estão os dados e quais sinais merecem atenção antes da modelagem.



REGISTROS

Base 1 – 438.557
Base 2 – 1.048.575



CLIENTES ANALISADOS

36.457



TARGET

ATRASSO $\geq$ 30 DIAS



MAUS PAGADORES

11,77%

LEITURA EXECUTIVA

A base final reúne aproximadamente 36,5 mil clientes e apresenta uma classe minoritária relevante. Cerca de 12% são maus pagadores, fator que exige atenção na modelagem e na escolha das métricas de avaliação.

Tratamentos para tornar os dados modeláveis

1

Ausências

Ocupação sem informação foi mantida como "Unknown".

2

Consistência

IDs cadastrais conflitantes foram removidos.

3

Novas variáveis

Idade, tempo de emprego e log da renda.

4

Codificação

Variáveis categóricas convertidas para números.

Divisão Estratificada



80%

treino

20%

teste

Random Forest teve o maior F1 médio



A disputa no topo

ZOOM • F1 MÉDIO

Árvore	0.3944
Random Forest	0.4035

+0,0091
diferença entre os dois primeiros

Resultado mais alto, mas vantagem pequena.

O modelo acerta a maioria, mas ainda deixa risco passar

80%
Acurácia

32%
Precisão

63%
Recall

43%
F1

MATRIZ DE CONFUSÃO • 7.292 CLIENTES DE TESTE

	Previsto: bom	Previsto: mau
Real: bom	5.309 acertos	1125 falsos alarmes
Real: mau	321 riscos não detectados	537 riscos detectados

Conclusão

O que funcionou

- ✓ Automação e Eficiência de Larga Escala
- ✓ Bloqueio Preventivo de Prejuízos:
- ✓ Estratégias de Mitigação de Risco
- ✓ Previsibilidade Financeira e Calibração de Reservas

Pontos de Aprimoramento

- ✓ Natureza Estática e Autorreferencial dos Dados
- ✓ Desafio de Classes Raras e Cardinalidade em Profissões
- ✓ Restrição Algorítmica e Falta de Otimização

Próximos passos

- ✓ APIs de reguladores de crédito tradicionais e dados de Open Finance.
- ✓ Alta cardinalidade e amostras microscópicas
- ✓ Otimização Bayesianas ou um GridSearchCV

LEITURA EXECUTIVA

Nenhum modelo preditivo é uma ferramenta perfeita e imune a falhas. Expor as limitações técnicas e de dados deste projeto de forma transparente não é um sinal de ineficiência, mas sim o selo de governança