

Relatório Executivo

Capítulo 1: Alinhamento de Negócio e Definição da Variável Alvo

1.1 O Desafio Comercial e a Necessidade de Automação

No cenário bancário contemporâneo, a concessão de cartões de crédito opera sob a constante fricção entre dois vetores concorrentes: a necessidade de agilidade na resposta ao cliente e o rigor no controle de perdas financeiras. Políticas tradicionais baseadas em árvores de decisão manuais ou scorecards de corte rígido comprometem a escalabilidade da operação e falham em identificar interações sutis e não-lineares nos perfis dos proponentes. A introdução de modelos de Machine Learning nesta esteira de crédito justifica-se pela oportunidade de converter o histórico de comportamento financeiro e dados cadastrais em recomendações estatísticas e probabilísticas objetivas, automatizando a tomada de decisão com consistência e escala.

1.2 Mecânica de Construção da Variável Target

A definição do comportamento de risco não pode ser arbitrária. Para construir a variável resposta (TARGET), o projeto utilizou a base histórica de comportamento mensal de pagamentos (df_credit_record). O histórico original registrava a coluna ordinal STATUS dividida em 8 categorias: meses sem empréstimos (X), meses quitados em dia (C), e atrasos divididos em faixas de tempo (0 para 1–29 dias; 1 para 30–59 dias; até 5 para inadimplência crítica e prejuízo).

O limiar de binarização técnico e de mercado adotado fixou a quebra de confiança a partir de atrasos $\geq$ a 30 dias (status 1, 2, 3, 4 e 5). O mapeamento seguiu a regra do pior cenário histórico (máximo): Se um cliente único registrou status maior ou igual a 1 em qualquer mês do seu histórico, ele foi classificado permanentemente como Mau Pagador (1.0); caso contrário, foi classificado como Bom Pagador (0.0).

Distribuição Original Mensal (STATUS) → Agregação pelo Pior Caso Histórico (ID)

[C, X, 0] → Mapeados como BOM PAGADOR (0.0)

[1, 2, 3, 4, 5] → Mapeados como MAU PAGADOR (1.0) (Atraso $\geq$ 30 dias)

Após o cruzamento com a base cadastral de proponentes (df_application_record), a base final unificada totalizou 36.457 clientes analisados, revelando uma taxa de 11,77% de classe minoritária (Maus Pagadores). Esse forte desbalanceamento reflete a realidade do mercado de concessão e determinou de forma direta o desenho de todo o pipeline de treinamento e avaliação de modelos.

Capítulo 2: Saneamento, Engenharia de Atributos e Estratégia de Partição

2.1 Sanidade dos Dados e Tratamento de Omissões

Antes de submeter os dados aos classificadores matemáticos, aplicou-se um rigoroso protocolo de saneamento para neutralizar ruídos e inconsistências sem descartar registros volumétricos essenciais:

- Tratamento de Dados Faltantes: A variável OCCUPATION_TYPE (tipo de ocupação) apresentava um volume expressivo de dados nulos originais. Em vez de imputar valores baseados em moda ou descartar as linhas, a ausência de informação foi tratada como uma categoria explícita chamada Unknown. Essa abordagem preserva o sinal de negócio, dado que a omissão da profissão pode, estatisticamente, correlacionar-se com diferentes perfis de risco.

- Consistência de Chaves: IDs cadastrais conflitantes ou duplicados que exibiam registros ambivalentes foram expurgados para garantir a unicidade e a integridade referencial dos dados.

2.2 Feature Engineering (Engenharia de Atributos)

Três transformações fundamentais foram implementadas para extrair o máximo valor preditivo das variáveis primitivas:

1. Idade em Anos (AGE_YEARS): Conversão da contagem original de dias corridos (DAYS_BIRTH) para anos positivos absolutos, facilitando a interpretação algorítmica e a análise bivariada.

2. Tempo de Emprego (EMPLOYED_YEARS): Conversão da variável de dias trabalhados (DAYS_EMPLOYED) para escala anual. O valor anômalo técnico 365243 (código para clientes

desempregados/pensionistas) foi isolado via criação de uma flag binária de suporte chamada EMPLOYED_SPECIAL_VALUE, mapeando o tempo de emprego real para -1.0 nesses cenários para evitar distorções nos cálculos de distância geométrica.

3. Renda Suavizada (LOG_INCOME): Aplicação de transformação logarítmica de base natural (loglp) sobre o rendimento bruto total (AMT_INCOME_TOTAL). Essa operação suaviza a assimetria à direita provocada por outliers de salários excepcionalmente elevados, estabilizando a variância e otimizando a convergência de modelos lineares e de distância.

2.3 Blindagem de Dados: Codificação e Partição Estratificada
Para viabilizar o processamento pelos algoritmos, as variáveis categóricas foram submetidas ao One-Hot Encoding, sendo expandidas em flags binárias numéricas (float64) para cada categoria.

Com os dados tratados, o conjunto de dados de 36.457 clientes foi dividido em 80% para Treinamento e 20% para Teste. Sob a semente fixa RANDOM_STATE = 42, utilizou-se obrigatoriamente a estratificação (stratify=y), assegurando que a exata proporção de 11,77% de maus pagadores fosse mantida tanto na base de treino quanto na de teste, blindando a avaliação final contra distorções estatísticas.

Capítulo 3: Arquitetura de Modelagem e Avaliação sob Validação Cruzada

3.1 Prevenção de Vazamento de Dados (Data Leakage) via Pipelines
Algoritmos baseados em distâncias e hiperplanos, como a Regressão Logística e o SVM, exigem a padronização das escalas numéricas. Para realizar essa operação de forma metodologicamente aceita, encapsulou-se o processador StandardScaler e os estimadores de classificação dentro de estruturas unificadas de Pipeline do scikit-learn. Essa arquitetura garante que o cálculo da média e do desvio padrão ocorra de forma isolada em cada subconjunto de treino, eliminando qualquer risco de vazamento de informações do conjunto de teste para a fase de aprendizado.

3.2 O Combate ao "Chute Cego" (Class Weighting)
Testes preliminares demonstraram que, devido ao desbalanceamento, os modelos lineares tendiam a ignorar a classe minoritária, maximizando a acurácia global ao classificar todos os clientes como bons pagadores (gerando recall zero na classe 1). Para quebrar essa inércia, injetou-se o parâmetro class_weight='balanced' nos estimadores. Essa técnica altera a função de perda dos algoritmos, penalizando severamente o erro na classe minoritária e forçando os modelos a mapearem os padrões de risco dos inadimplentes.

3.3 Confronto Estatístico via Validação Cruzada (5-Fold CV)
A escolha do classificador definitivo baseou-se na performance de Validação Cruzada Estratificada com 5 dobras, utilizando o F1-Score como métrica soberana de seleção, dado que ela pondera o equilíbrio entre Precisão e Recall na classe alvo:

Ranking	Modelo Candidato	Média do F1-Score (5-Fold CV)	Características de Desempenho
1º 🏆	Random Forest	0,4035	Maior robustez geral; excelente mapeamento de não-linearidades.
2º 🥈	Árvore de Decisão	0,3944	Performance próxima ao líder (diferença de apenas +0,0091).
3º 🥉	Support Vector Machine	0,2798	Estável após escalonamento, mas penalizado pela baixa precisão.
4º 🏹	Regressão Logística	0,2072	Modelo linear estável, mas limitado para capturar interações complexas.

O Random Forest consagrou-se como o classificador campeão devido à sua superior capacidade de generalização ao combinar múltiplas árvores de decisão não correlacionadas (bagging), reduzindo a variância global sem sacrificar o poder de captura de risco.

Capítulo 4: Métricas do Modelo Final, Diagnóstico de Negócio e Conclusões

4.1 Desempenho Factual na Base de Teste (7.292 Clientes)

Submetido ao conjunto de teste (uma amostra inédita que simula o ambiente de produção do banco), o modelo Random Forest consolidou os seguintes indicadores macro:

- Acurácia Global: 80% – O modelo acerta a classificação geral de 8 em cada 10 novos

proponentes.

- Recall (Sensibilidade): 63% – Capacidade de capturar e bloquear a maioria dos inadimplentes estruturais da carteira.
- Precisão: 32% – Dos alarmes de risco gerados, cerca de um terço representam maus pagadores reais.
- F1-Score Final: 43% – Equilíbrio otimizado para cenários severamente desbalanceados.

4.2 Anatomia do Impacto Financeiro (Matriz de Confusão)
O mapeamento físico dos 7.292 clientes de teste revela a distribuição real das decisões do classificador e seu impacto direto no caixa da instituição financeira:

MATRIZ DE CONFUSÃO (Random Forest Final)

	PREVISTO: BOM	PREVISTO: MAU
REAL: BOM	5.309	1.125
	Verdadeiros Negativos (Acertos)	Falsos Positivos (Falsos Alarmes)
REAL: MAU	321	537
	Falsos Negativos (Risco Oculto)	Verdadeiros Positivos (Inadimplência Paga)

- Inadimplência Prevenida (Verdadeiros Positivos - 537): Representa o sucesso direto do modelo. São 537 clientes de alto risco que foram identificados e bloqueados na esteira de aprovação automatizada, estancando a perda financeira com linhas de crédito que se tornariam inadimplentes.
- Falsos Alarmes Comerciais (Falsos Positivos - 1.125): Clientes com perfil saudável, mas que foram classificados como risco pelo modelo. Representa um custo de oportunidade comercial, onde a instituição deixa de rentabilizar imediatamente, exigindo um direcionamento para uma esteira de revisão humana para refinar a concessão sem frustrar o cliente legítimo.
- O Risco Oculto Ativo (Falsos Negativos - 321): O indicador mais sensível para o comitê de risco. São 321 maus pagadores que burlaram a barreira preditiva e foram aprovados como bons clientes. Este grupo representa a taxa residual de inadimplência ativa que consumirá as provisões bancárias de perdas estimadas.

4.3 Feature Importance e Consideração Causal

A análise de importância de recursos do Random Forest indicou quais dados cadastrais forneceram maior ganho estatístico para diferenciar os perfis. No modelo final, as três variáveis mais selecionadas para realizar a separação e quebra dos nós das árvores foram a Idade (AGE_YEARS), o Tempo de Emprego (EMPLOYED_YEARS) e a Renda Suavizada (LOG_INCOME).

Do ponto de vista metodológico, o comitê de ciência de dados ressalta que essa liderança indica uma forte correlação estatística e associação preditiva nos dados históricos, e não uma relação direta de causa e efeito. O modelo captura que clientes de faixas etárias mais avançadas ou com maior tempo de estabilidade empregatícia registram perfis estatísticos mais seguros devido à consolidação de seus hábitos financeiros, operando como excelentes variáveis aproximadas (proxies) de comportamento de risco.

4.4 Próximos Passos e Evolução do Projeto

Nenhum modelo preditivo é uma ferramenta perfeita e imune a falhas. Para o aprimoramento contínuo da governança de risco da instituição, recomendam-se os seguintes passos estratégicos:

1. Dados Alternativos e Open Finance: Superar a natureza estática dos dados

cadastrais integrando APIs de Open Finance e bureaus de crédito tradicionais para capturar o comportamento de consumo e fluxo de caixa do cliente em tempo real.

2. Otimização Bayesiana: Substituir os parâmetros padrão por uma busca exaustiva via otimização bayesiana ou GridSearchCV para refinar os hiperparâmetros do Random Forest.

3. Modelos de Boosting Avançados: Testar frameworks mais complexos de gradiente (como XGBoost, LightGBM ou CatBoost), que tendem a extrair maior eficiência em problemas com classes raras e alta cardinalidade de profissões, elevando o teto do F1-Score do sistema preditivo.